

常州工学院

CHANGZHOU INSTITUTE OF TECHNOLOGY

课程设计报告

课程名称: 专业方向课程设计

二级学院: 计算机信息工程学院

课题名称: 基于 RAG 与多智能体协作的
知识服务平台

班 级: 23 软一

学 号: 23030327

姓 名: 许子祺

指导教师: 蒋巍

2026 年 7 月

基于 RAG 与多智能体协作的知识服务平台

摘 要

现有知识管理系统普遍存在检索精度不足、智能体缺乏自主反思能力、 workflow 编排灵活性受限等问题。针对上述挑战，本文设计并实现了一个基于 RAG 与多智能体协作的知识服务平台。

平台采用“控制面 + 认知面”双核架构。控制面基于 Spring Boot 3 构建，负责权限管理、RAG 知识引擎与 DAG workflow 编排；认知面以 Hermes 内核为核心，通过 gRPC 实现反思循环推理与 AI Judge 三维质量评分。RAG 引擎支持文档语义切块、三路并行召回与 Reciprocal Rank Fusion 融合，并引入 CRAG 机制对检索结果自动修正。智能体编排支持 SupervisorAgent 任务分解、WorkerAgent ReAct 推理与三层记忆体系。workflow 引擎基于 DAG 拓扑排序实现多节点并行执行，支持条件网关与断点恢复。质量评估集成 AI Judge、RAGAS 与 RAGChecker，形成完整闭环。

前端采用 Vue 3 构建可视化 DAG 画布与对话界面，后端使用 PostgreSQL + PgVector 实现向量检索，Neo4j 支撑知识图谱，Redis 提供缓存管理。实验表明，平台在 RAG 检索任务上达到了较高的召回精度，多智能体协作机制有效提升了复杂问答质量。

关键词：RAG；多智能体；知识服务；workflow 编排；Hermes 认知内核

A Knowledge Service Platform Based on RAG and Multi-Agent Collaboration

Abstract

Existing knowledge management systems commonly suffer from low retrieval accuracy, lack of agent self-reflection, and limited workflow flexibility. To address these challenges, this paper designs and implements a knowledge service platform based on RAG and multi-agent collaboration.

The platform adopts a dual-core architecture of control plane and cognitive plane. The control plane, built on Spring Boot 3, handles authorization, the RAG knowledge engine, and DAG workflow orchestration. The cognitive plane, centered on the Hermes kernel, implements reflective reasoning and AI Judge quality scoring via gRPC. The RAG engine supports semantic chunking, tri-channel parallel retrieval with Reciprocal Rank Fusion, and a CRAG mechanism for automatic correction. Agent orchestration enables SupervisorAgent task decomposition, WorkerAgent ReAct reasoning, and a three-layer memory system. The workflow engine achieves parallel execution via DAG topological sorting with conditional gateways and checkpoint recovery. Quality evaluation integrates AI Judge, RAGAS, and RAGChecker into a closed loop.

The frontend provides a visual DAG canvas and conversation interface using Vue 3. The backend employs PostgreSQL with PgVector for vector retrieval, Neo4j for knowledge graphs, and Redis for caching. Experiments show that the platform achieves high recall precision, and multi-agent collaboration effectively improves complex QA quality.

Keywords: RAG; multi-agent; knowledge service; workflow orchestration; Hermes cognitive kernel

目 录

第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 研究内容与主要贡献	2
第 2 章 系统设计与方法	3
2.1 系统总体架构	3
2.1.1 双核架构设计	3
2.1.2 模块依赖结构	4
2.2 RAG 检索引擎设计	4
2.2.1 文档预处理：语义切块策略	5
2.2.2 查询转换与意图分析	7
2.2.3 四路并行召回	8
2.2.4 候选融合：Reciprocal Rank Fusion	11
2.2.5 两阶段重排序	12
2.2.6 Corrective RAG 质量评估	12
2.3 Hermes 认知内核设计	13
2.3.1 反思循环推理	13
2.3.2 多智能体协作	16
2.3.3 三层记忆体系	17
2.3.4 工具韧性机制	19
2.4 DAG workflow 引擎设计	19
2.4.1 拓扑排序与并行分组	19
2.4.2 执行引擎	20
2.4.3 双层持久化检查点	20
2.4.4 节点类型体系	21
2.4.5 表达式引擎安全设计	21
2.5 质量评估框架设计	22
2.5.1 AI Judge 三维在线评分	22
2.5.2 RAGAS 七维离线评估	22
2.5.3 RAGChecker 声明级蕴含判断	23

2.5.4 LangFuse 全链路追踪	23
第 3 章 系统具体实现	25
3.1 开发环境与技术选型	25
3.2 gRPC 通信协议实现	25
3.3 RAG 检索引擎实现	26
3.3.1 文档切块实现	26
3.3.2 向量存储实现	26
3.3.3 检索服务实现	27
3.3.4 上下文构建实现	27
3.4 Hermes 认知内核实现	27
3.4.1 反思循环实现	27
3.4.2 智能体编排实现	28
3.4.3 Plan-and-Solve 实现	28
3.4.4 记忆系统实现	28
3.5 DAG 工作流引擎实现	29
3.5.1 节点执行模板	29
3.5.2 条件分支实现	29
3.5.3 流式输出实现	29
3.5.4 人工审批实现	29
3.6 前端实现	30
3.6.1 DAG 画布实现	30
3.6.2 流式通信实现	30
3.7 安全实现	30
3.7.1 认证流程	30
3.7.2 RBAC 授权	30
第 4 章 实验	31
4.1 实验环境	31
4.2 功能验证	31
4.2.1 RAG 知识引擎	31
4.2.2 Hermes 认知内核	32
4.2.3 DAG 工作流引擎	32
4.3 性能基准测试	32

4.4 质量评估	33
4.4.1 RAGAS 七维评估	33
4.4.2 RAGChecker 声明级蕴含判断	33
4.5 本章小结	34
第 5 章 总结与展望	35
5.1 工作总结	35
5.2 不足与展望	35
5.2.1 当前不足	35
5.2.2 未来展望	35
致 谢	37
参考文献	39

第 1 章 绪论

1.1 研究背景与意义

随着大语言模型 (LLM) 技术的快速发展,人工智能在自然语言处理、知识推理和代码生成等领域取得了突破性进展,企业对智能化知识管理与自动化业务流程的需求日益迫切。然而,现有知识管理系统在实际应用中仍面临诸多挑战:传统的基于关键词的检索方法难以理解用户查询的语义意图,单一检索路径在面对复杂查询时召回率有限;现有 LLM 智能体系统通常采用“生成即返回”的模式,缺少对生成结果的质量评估和自修正机制,容易产生幻觉回答;工作流引擎多采用线性结构,缺乏并行执行与断点恢复能力;企业知识分散在文档、数据库、知识图谱等多种载体中,缺乏统一的融合检索机制^[1]。针对上述问题,本文设计并实现了一个基于 RAG (Retrieval-Augmented Generation)^[2]与多智能体协作的知识服务平台。该平台采用“控制面+认知面”双核架构,控制面基于 Spring Boot 3 构建,负责权限管理、RAG 知识引擎与 DAG 工作流编排;认知面以自研 Hermes 内核为核心,通过 gRPC 协议与控制面通信,实现反思循环推理与质量评分。在检索层面,平台通过“四路并行召回+RRF 融合”策略和 CRAG^[3]质量评估机制显著提升了检索精度;在推理层面,通过“反思循环+自洽性检测”双重质量保障机制有效识别和修正幻觉回答,为企业级智能知识服务提供了完整的解决方案。

1.2 国内外研究现状

RAG 技术方面, Lewis 等人^[2]提出了 RAG 框架, Karpukhin 等人^[4]的密集检索显著优于 BM25, Cormack 等人^[5]的 RRF 实现了多路融合。在质量保障方面, CRAG^[3]引入检索质量评估, Self-RAG^[6]实现了自反思机制。重排方面, ColBERT^[7]的后期交互架构降低了计算开销。

多智能体协作方面, ReAct^[8]范式将推理与行动交替进行, CoT^[9]引导模型生成中间推理步骤, Plan-and-Solve^[10]实现了先规划后执行。MemGPT^[11]借鉴虚拟内存思想实现了分层记忆管理, LightRAG^[12]通过知识图谱双层检索提升了查询效果。

工作流与评估方面, Kahn^[13]的拓扑排序算法为 DAG 工作流的依赖解析提供了理论基础。在 AI 工作流编排中, LangGraph 等框架将智能体推理过程建模为有向图,支持条件分支、并行执行和持久化检查点。质量评估方面, RA-

GAS^[14]提出了七维度 RAG 评估体系，涵盖忠实度、相关性、精确度和召回率等指标；RAGChecker^[15]采用声明级蕴含判断方法，在 NeurIPS 2024 上被证明与人类评价具有更高的相关性。LangFuse 等可观测性平台则提供了从检索到生成的全链路追踪能力。

1.3 研究内容与主要贡献

(1) 提出”控制面+认知面”双核架构：控制面负责 RAG 引擎与 DAG workflow 编排，认知面以 Hermes 内核为核心实现反思循环推理，两者通过 gRPC 完全解耦。

(2) 设计四路并行召回+RRF 融合检索引擎：同时运行向量、关键词、元数据和知识图谱四条检索路径，通过 RRF 融合排序并引入 CRAG^[3]质量评估与自动修正。

(3) 提出带自洽性检测的反思循环机制：实现”生成→AI Judge 三维评分→Jaccard 自洽性检测→修正”的双重质量保障闭环。自洽性检测通过对同一提示词进行多次独立采样并计算成对 Jaccard 相似度，有效识别”看似合理但实际不可靠”的幻觉回答。

(4) 实现 DAG 并行 workflow 引擎：基于 Kahn 算法^[13]拓扑排序与 BFS 分层并行分组，支持 8 种节点类型（含条件网关、人工审批和知识检索），通过双层持久化检查点（Redis 快照级+PostgreSQL 分组级）实现断点恢复。

(5) 构建完整质量评估体系：集成 RAGAS^[14]七维评估、RAGChecker^[15]声明级蕴含判断和 LangFuse 全链路追踪。

第 2 章 系统设计与方法

本章详细阐述平台的整体架构设计和核心算法原理。首先介绍系统的双核架构和模块划分，然后依次论述 RAG 检索引擎^[2]、Hermes 认知内核^[6]、DAG 工作流引擎^[13]和质量评估框架^[14-15]的设计与方法。每个算法均给出形式化定义、数学推导和关键参数分析。本章引用的核心文献涵盖检索增强生成^[1-2]、密集向量检索^[4,16]、排序融合^[5,7]、自反思推理^[3,6]、多智能体协作^[8-10]、分层记忆管理^[11]、图增强检索^[12]以及质量评估^[14-15]等前沿研究成果。

2.1 系统总体架构

2.1.1 双核架构设计

本平台采用”控制面 (Control Plane) + 认知面 (Cognitive Plane)”双核架构^[2]。两个面通过 gRPC 协议进行通信，实现了业务逻辑与 AI 推理的完全解耦。这种设计灵感来源于现代操作系统的用户态/内核态分离思想：控制面如同用户态，负责资源管理和业务规则；认知面如同内核态，专注于核心推理任务。与传统的单体 RAG 系统相比，双核架构的核心优势在于将检索 (Retrieval) 与生成 (Generation) 解耦到不同的运行时环境中，使得每个面可以独立扩展和优化。Lewis 等人^[2]在 RAG 原始论文中指出，参数化记忆 (LLM 权重) 和非参数化记忆 (检索索引) 的分离是 RAG 系统的关键设计原则，本平台的双核架构正是这一原则的工程化实现。

控制面基于 Spring Boot 3 构建，是一个模块化单体应用，承担以下职责：

- RBAC 权限管理：基于角色的访问控制，支持数据范围过滤
- RAG 知识引擎^[2]：文档上传、语义切块、向量化存储与混合检索
- 工具注册中心：内置工具管理与 MCP 协议适配
- DAG 工作流编排^[13]：前端可视化画布与后端执行引擎
- API 网关：统一的 RESTful API 与 SSE 流式响应

认知面以自研 Hermes 内核为核心，是一个独立的 Spring Boot 微服务，承担以下职责：

- 反思循环推理^[6]：生成 → 评估 → 修正的闭环推理
- ReAct 工具调用^[8]：基于推理-行动范式的工具编排
- AI Judge 质量评分^[14]：三维（事实性、相关性、指令遵循度）自动评分
- 多智能体协作^[10]：Supervisor-Worker 模式的任务分解与并行执行

这种设计的核心优势在于：控制面负责数据持久化和业务规则，认知面专注于 AI 推理，两者通过 Protobuf 定义清晰的接口边界。控制面在将请求发送给认知面之前，预先完成 API Key 解析、RAG 上下文检索等数据准备工作，使认知面成为无状态的纯推理引擎。

2.1.2 模块依赖结构

控制面采用 Maven 多模块结构，共包含 8 个业务模块和 12 个框架模块。

框架层 (qknow-framework) 包含以下子模块：qknow-common (公共工具类与基础实体)、qknow-config (Web 与 AOP 配置)、qknow-mybatis (ORM 与数据源)、qknow-redis (缓存与会话)、qknow-security (安全框架)、qknow-neo4j (图数据库驱动)、qknow-ai (AI 框架层)、qknow-websocket (WebSocket 支持)、qknow-quartz (定时任务)、qknow-generator (代码生成)、qknow-thirdparty (第三方集成) 和 qknow-file (文件存储)。

业务层包含以下模块：qknow-module-system (RBAC 系统管理)、qknow-module-ai (AI 模型市场)、qknow-module-kmc (知识管理中心)、qknow-module-kb (Agent 平台核心)、qknow-module-kg (知识图谱)、qknow-module-ext (知识抽取)、qknow-module-app (应用目录) 和 qknow-module-dm (数据管理)。

每个业务模块遵循 API/BIZ 分离模式：<module>-api 包含 DTO、实体和接口定义，<module>-biz 包含控制器、服务和 Mapper 实现。这种模式实现了跨模块的类型共享，同时避免了实现依赖的传递。

2.2 RAG 检索引擎设计

RAG (Retrieval-Augmented Generation) 是一种通过检索外部知识库来增强大语言模型生成能力的技术范式^[2]。其核心思想是：给定用户查询 q ，首先从知识库 $\mathcal{D}$ 中检索相关文档集合 $\mathcal{R}(q) \subset \mathcal{D}$ ，然后将检索结果作为上下文注入 LLM 的提示词中，引导模型基于外部知识生成更准确的回答^[1]。形式化地：

$$\text{RAG}(q) = \text{LLM}(q, \mathcal{R}(q)) = \text{LLM}(q, \{d_1, d_2, \dots, d_k\}) \quad (2.1)$$

其中 $\mathcal{R}(q) = \{d_1, d_2, \dots, d_k\}$ 为检索到的 top- k 文档。RAG 技术有效缓解了 LLM 的幻觉问题，使模型能够基于外部知识生成更准确的回答^[1]。Gao 等人^[1]在 RAG 综述中指出，RAG 系统的核心挑战包括检索质量（如何找到最相关的文档）、上下文利用（如何有效利用检索结果）和生成质量（如何基于上下文生成准确的

回答) 三个方面。

本平台的 RAG 检索引擎采用” 四路并行召回 + RRF 融合 + 两阶段重排 + CRAG 质量评估” 的四层架构。下面依次介绍每个环节的设计原理和算法细节。

2.2.1 文档预处理：语义切块策略

文档切块是 RAG 系统的基础环节。Anthropic^[17]的研究表明，在嵌入和索引之前为每个文档块添加上下文信息 (Contextual Retrieval)，可以将检索失败率降低 49%–67%。本平台借鉴了这一思想，在切块阶段保留了文档结构信息和元数据。设文档 D 由字符序列 $D = (c_1, c_2, \dots, c_N)$ 组成，切块的目标是将其划分为 m 个语义完整的块 $\{s_1, s_2, \dots, s_m\}$ ，使得每个块的大小在预设范围内，且语义边界处的信息损失最小化。

2.2.1.1 递归字符切块 (RecursiveSplitter)

递归字符切块是默认的切块策略，其设计灵感来源于 LangChain 的 RecursiveCharacterTextSplitter。核心思想是按照分隔符优先级逐级尝试切分：设分隔符集合为 $S = (s_1, s_2, \dots, s_p)$ ，按优先级从高到低排列。算法首先使用最高优先级的分隔符 s_1 切分文本；若切分后的片段长度仍超过目标块大小 $L_{\max}$ ，则递归使用下一级分隔符 s_2 对该片段进一步切分；依此类推。

分隔符优先级从高到低依次为：段落分隔符 ($\backslash n \backslash n$)、换行符 ($\backslash n$)、句号 (。)、分号 (;)、感叹号 (!)、问号 (?)、逗号 (,)、空格 () 和字符级切分。这种设计遵循了中文文本的语义边界，优先在段落和句子层面进行切分，最大程度地保持了语义完整性。

递归切块的形式化定义为：给定文本 T 、分隔符序列 S 、目标块大小 $L_{\max}$ 和重叠大小 δ ，切块函数 $\text{Split}(T, S, i)$ 定义为：

$$\text{Split}(T, S, i) = \begin{cases} \text{HardCut}(T, L_{\max}) & \text{if } |T| \leq L_{\max} \text{ or } i > |S| \\ \text{Merge} \left(\bigcup_{t \in \text{SplitBy}(T, S_i)} \text{Split}(t, S, i+1) \right) & \text{otherwise} \end{cases} \quad (2.2)$$

其中 $\text{SplitBy}(T, s)$ 按分隔符 s 切分文本， $\text{HardCut}(T, L)$ 按字符硬切分， $\text{Merge}(\cdot)$ 将过短的相邻块合并。

重叠机制确保语义边界处的信息不丢失。对于相邻块 s_i 和 s_{i+1} ，重叠区域为：

$$\text{overlap}(s_i, s_{i+1}) = s_i[|s_i| - \delta : |s_i|] \quad (2.3)$$

即从前一个块的尾部取 δ 个字符拼接到当前块的头部。

该算法还支持父子切块 (Parent-Child Chunking) 模式：首先以较大的块大小 L_{parent} 将文档切分为父块，然后在每个父块内部以较小的块大小 L_{child} 进一步切分为子块。设父块为 P_j ，其子块集合为 $\{s_{j,1}, s_{j,2}, \dots, s_{j,n_j}\}$ ，则每个子块通过元数据 $\text{parent_id}(s_{j,k}) = j$ 关联到父块。检索时使用子块进行精确匹配，上下文扩展时回溯到父块获取完整语境。

2.2.1.2 语义切块 (SemanticSplitter)

语义切块^[18]基于文本嵌入的语义相似度来确定切分边界，其核心假设是：语义主题发生转换的位置，相邻句子的嵌入向量之间的余弦相似度会显著下降。嵌入模型基于 Transformer 架构^[18]，通过自注意力机制将句子映射到 d 维稠密向量空间。自注意力机制的核心计算为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.4)$$

其中 Q 、 K 、 V 分别为查询、键、值矩阵， d_k 为键向量维度。通过多头注意力机制，模型能够捕获句子中不同位置的语义信息，生成高质量的句向量表示。

给定句子序列 $(s_1, s_2, \dots, s_n)$ ，语义切块算法的执行流程如下：

步骤一：句子分割。按中英文句号、感叹号、问号、分号和换行符将文本切分为句子序列。

步骤二：批量嵌入计算。以批量大小为 10 调用 EmbeddingModel 对每个句子生成 d 维向量表示 $\mathbf{e}_i \in \mathbb{R}^d$ 。

步骤三：断点检测。计算相邻句子对的余弦相似度：

$$\text{sim}(s_i, s_{i+1}) = \cos(\mathbf{e}_i, \mathbf{e}_{i+1}) = \frac{\mathbf{e}_i \cdot \mathbf{e}_{i+1}}{\|\mathbf{e}_i\|_2 \cdot \|\mathbf{e}_{i+1}\|_2} = \frac{\sum_{j=1}^d e_{i,j} \cdot e_{i+1,j}}{\sqrt{\sum_{j=1}^d e_{i,j}^2} \cdot \sqrt{\sum_{j=1}^d e_{i+1,j}^2}} \quad (2.5)$$

当相似度低于阈值 $\theta_s = 0.5$ 时，将位置 $i + 1$ 标记为断点： $B = \{i + 1 : \text{sim}(s_i, s_{i+1}) < \theta_s\}$ 。

步骤四：分组。将断点之间的句子组合为文档块。设断点序列为 $b_1 < b_2 < \dots < b_k$ ，则第 j 个块为 $C_j = (s_{b_{j-1}}, s_{b_{j-1}+1}, \dots, s_{b_j-1})$ ，需满足 $|C_j| \in [L_{\min}, L_{\max}]$ 。

语义切块的优势在于能够自适应地识别语义边界，避免在主题内部强行切分。但其计算开销较高（需要对每个句子生成嵌入向量），适用于对切块质量要求较高的场景。

2.2.1.3 模板切块 (TemplateSplitter)

模板切块根据文件类型自动选择最优的切块策略，体现了“分而治之”的设计思想。其核心是一个文件类型到切块策略的映射函数 $\tau: \mathcal{P} \rightarrow \mathcal{A}$ ，其中 $\mathcal{P}$ 为文件类型集合， $\mathcal{A}$ 为切块策略集合。

映射规则如下：Markdown 文件使用标题级别 (`\n##`、`\n###`) 作为主要分隔符，利用文档结构语义进行切分；代码文件 (Java、Python、JavaScript 等) 使用函数定义 (`\ndef`、`\nfunction`、`\npublic`) 和类定义 (`\nclass`) 作为分隔符，确保代码块的完整性；PDF 文件使用默认分隔符但将最大块大小扩展至 1024 字符，适应 PDF 文档的段落较长的特点；CSV/TSV 文件按行切分，保持数据记录的原子性。

2.2.2 查询转换与意图分析

在检索之前，平台对用户查询进行多层次的转换和分析，以提高检索的召回率和精确率。

2.2.2.1 查询路由 (QueryRouter)

查询路由将用户查询分为三个复杂度级别，其形式化定义为分类函数 $\phi: \mathcal{Q} \rightarrow \{\text{SIMPLE}, \text{MEDIUM}, \text{COMPLEX}\}$ 。

分类逻辑采用三级判定策略：

(1) **正则意图匹配**：若查询匹配检索意图正则模式 $\mathcal{P}_{\text{retrieval}}$ (包含“第一天”、“Day\d+”、“日志”、“文档”等关键词)，直接判定为 MEDIUM。

(2) **规则快速路径**：若 $|q| < 10$ 或 $q \in \mathcal{P}_{\text{simple}}$ (“你好”、“谢谢”、“时间”等)，判定为 SIMPLE。

(3) **LLM 分类**：对不确定的查询调用 LLM 进行分类。

SIMPLE 级别的查询跳过检索直接由 LLM 回答，避免了不必要的检索开销。

2.2.2.2 查询转换策略 (QueryTransformService)

查询转换旨在弥合用户查询与文档表述之间的语义鸿沟。平台支持四种策略：

(1) **查询重写 (rewrite, 默认策略)**。调用 LLM 将查询改写为更适合文档检索的形式。设原始查询为 q ，重写函数为 f_r ，则转换后的查询为 $q' = f_r(q)$ 。重写提示词为：“Rewrite search queries to be more specific for document retrieval.”

(2) **假设文档嵌入 (HyDE)**。HyDE 的核心思想是：先让 LLM 生成一个假设性的回答文档 $\hat{d}$ ，然后用 $\hat{d}$ 的嵌入向量作为查询代理进行检索。该方法的理论基

础是：假设文档的表述更接近实际文档的表述，从而缩小了查询与文档之间的语义鸿沟（semantic gap）^[1]。形式化地：

$$\hat{d} = \text{LLM}(q), \quad \mathbf{q}_{\text{hyde}} = \text{Embed}(\hat{d}), \quad \mathcal{R}_{\text{hyde}}(q) = \text{TopK}_{d \in \mathcal{D}}(\cos(\mathbf{q}_{\text{hyde}}, \mathbf{e}_d)) \quad (2.6)$$

其优势在于假设文档的表述更接近实际文档，从而提高了查询-文档的语义匹配度。对于包含数字的查询（如日期、版本号），跳过 HyDE 以避免生成不准确的假设。

(3) 多查询扩展 (multi_query)。生成 v 个语义多样化的查询变体 $\{q_1, q_2, \dots, q_v\}$ （默认 $v = 3$ ），对每个变体分别进行检索，最后合并结果：

$$\mathcal{R}_{\text{multi}}(q) = \bigcup_{i=1}^v \mathcal{R}(q_i) \quad (2.7)$$

多查询扩展通过增加查询的覆盖面来提高检索的召回率，尤其适用于用户查询模糊或存在多种表述方式的场景。

2.2.2.3 查询实体抽取 (QueryEntityExtractionService)

使用 LLM 从查询中提取核心命名实体集合 $\mathcal{E}(q) = \{e_1, e_2, \dots, e_k\}$ ，其中 $k \leq 8$ ，每个实体长度 $|e_i| \geq 2$ 。抽取模型使用 DeepSeek deepseek-chat，温度参数设为 0.0 以确保确定性输出。抽取的实体用于元数据检索和知识图谱检索。

2.2.3 四路并行召回

本平台实现了四条并行检索路径，每条路径针对不同类型的查询模式进行优化。四路召回的形式化定义为：

$$\mathcal{R}_{\text{total}}(q) = \mathcal{R}_{\text{vector}}(q) \cup \mathcal{R}_{\text{keyword}}(q) \cup \mathcal{R}_{\text{metadata}}(q) \cup \mathcal{R}_{\text{graph}}(q) \quad (2.8)$$

四路检索通过线程池并行执行，每条路径的超时时间为 30 秒。候选 top-K 设置为 $\max(k \times 3, 50)$ ，其中 k 为最终返回的结果数。

2.2.3.1 向量检索 (VectorRetriever)

向量检索^[4]基于密集向量表示实现语义匹配。Karpukhin 等人^[4]在 EMNLP 2020 中证明，密集向量检索在开放域问答任务上显著优于传统的稀疏检索方法（如 BM25），top-20 检索准确率提升了 9%–19%。其核心思想是将查询和文档分别编码为低维密集向量，然后通过向量相似度计算检索最相关的文档。本平台使用

通义千问 Embedding 模型（1536 维）作为向量编码器，通过 Spring AI 的统一接口进行调用。

文档块的嵌入向量存储在 `vector_store` 表中，维度为 $d = 1536$ （与通义千问 Embedding 模型对齐）。向量索引使用 HNSW（Hierarchical Navigable Small World）算法^[16]，其核心数据结构是一个多层图 $G = (V, E)$ ，其中每个节点 $v \in V$ 对应一个文档向量，边集 E 编码了向量之间的近邻关系。Malkov 等人^[16]在 IEEE TPAMI 2018 中证明，HNSW 在近似最近邻搜索（ANN）任务上实现了 $O(\log N)$ 的查询时间复杂度，同时保持了较高的召回率。HNSW 的核心思想是构建一个层次化的导航图：底层包含所有向量节点，高层通过随机跳转实现快速导航，查询时从最高层开始逐层下降，最终在底层找到近似最近邻。

HNSW 的关键参数包括：

- $m = 16$ ：每个节点在非零层的最大连接数，控制图的密度
- $ef_construction = 200$ ：构建阶段的候选列表大小，影响索引质量
- $ef_search = 100$ ：查询阶段的候选列表大小，影响检索精度

查询时，将用户查询的嵌入向量 $\mathbf{q}$ 与存储的文档向量进行余弦相似度计算：

$$\text{score}_{\text{vector}}(d) = \cos(\mathbf{q}, \mathbf{e}_d) = \frac{\mathbf{q} \cdot \mathbf{e}_d}{\|\mathbf{q}\|_2 \cdot \|\mathbf{e}_d\|_2} \quad (2.9)$$

HNSW 索引的查询时间复杂度为 $O(\log N)$ ，远优于暴力搜索的 $O(Nd)$ ，其中 N 为文档数量。

2.2.3.2 关键词检索 (KeywordRetriever)

关键词检索利用 PostgreSQL 的原生全文检索能力。每个文档块在入库时自动计算 `content_tsv` (tsvector 类型)，使用 `simple` 配置（适用于中文）进行分词，并建立 GIN (Generalized Inverted Index) 索引。

倒排索引的核心数据结构是一个从词项到文档列表的映射 $\mathcal{I} : \mathcal{T} \rightarrow 2^D$ ，其中 $\mathcal{T}$ 为词项集合。查询时使用 `plainto_tsquery('simple', ?)` 函数将查询转换为 `tsquery`，然后通过索引查找包含所有查询词项的文档。

关键词检索的评分函数结合了文档名称匹配和内容匹配：

$$\text{score}_{\text{keyword}}(d) = \sum_{t \in \mathcal{E}(q)} [\alpha \cdot \mathbb{1}[t \in \text{name}(d)] + \beta \cdot \mathbb{1}[t \in \text{content}(d)]] \quad (2.10)$$

其中 $\alpha = 3.0$ 为文档名称匹配权重， $\beta = 1.0$ 为内容匹配权重， $\mathbb{1}[\cdot]$ 为指示函数。

2.2.3.3 元数据检索 (MetadataRetriever)

元数据检索利用 PostgreSQL 的 JSONB 包含操作符 (@>) 在实体元数据表中查找包含指定实体的文档块。该表 (kmc_segment_entity_metadata) 存储了每个文档块的实体和关系元数据 (由 LLM 在入库时抽取), 使用 GIN 索引加速查询。

元数据检索的查询逻辑为: 给定实体集合 $\mathcal{E}(q)$, 查找所有满足 $\mathcal{E}(q) \subseteq \text{entities}(d)$ 的文档块。所有匹配结果获得固定高置信度分数 10.0, 因为实体匹配是一种高精度的检索信号。

2.2.3.4 知识图谱检索 (GraphRagRetriever)

知识图谱检索^[12]实现了 LightRAG 风格的双层检索策略。Guo 等人^[12]提出, 基于图的 RAG 系统可以通过低层 (实体级) 和高层 (主题级) 两个粒度进行检索, 从而同时捕获精确的实体关系和宏观的语义关联。本平台借鉴了这一双层思想, 结合 PostgreSQL 邻接表和 Neo4j 图数据库实现了灵活的图增强检索。

低层检索 (Low-level): 通过精确实体匹配查找直接相关的文档块。给定实体 e , 检索所有在 kmc_segment_entity_metadata 中包含 e 的文档块。

高层检索 (High-level): 通过主题和概念匹配进行跨实体的语义检索。使用 ILIKE 模糊匹配查找与查询主题相关的实体, 然后通过知识图谱的边关系进行多跳扩展。

当 Neo4j 图数据库可用时, 系统执行语义引导的图遍历查询。给定查询实体集合 $\mathcal{E}$, 遍历所有距离不超过 $h_{\max} = 2$ 跳的邻居节点, 每个邻居 n 的权重计算为:

$$w(n) = \gamma^{h(n)} \cdot b(n) \quad (2.11)$$

其中 $h(n)$ 为节点 n 到查询实体的最短跳数, γ 为跳数衰减因子 ($h = 1$ 时 $\gamma^1 = 1.0$, $h = 2$ 时 $\gamma^2 = 0.7$), $b(n)$ 为相关性增强因子:

$$b(n) = \begin{cases} 2.0 & \text{if context} \subseteq \text{name}(n) \\ 1.0 & \text{otherwise} \end{cases} \quad (2.12)$$

此外, 系统还支持时间衰减检索, 对具有时间窗口 (valid_from、valid_until) 的事实信息, 按以下公式计算时间衰减分数:

$$\text{score}_{\text{temporal}}(d) = S_{\text{base}} \cdot \alpha_{\text{decay}}^{\frac{\Delta t}{T_{1/2}}} \quad (2.13)$$

其中 $S_{\text{base}} = 12.0$ 为图检索基础分数, $\alpha_{\text{decay}} = 0.9$ 为衰减因子, Δt 为事实创建至今的天数, $T_{1/2} = 30$ 为半衰期 (天)。该公式采用了指数衰减模型, 其物理含义是: 每隔 30 天, 事实的可信度衰减为原来的 0.9 倍。

2.2.4 候选融合: Reciprocal Rank Fusion

四路检索的结果需要融合为统一的排序列表。本平台采用 Reciprocal Rank Fusion (RRF) 算法^[5]进行融合。RRF 是一种基于排名的融合方法, 其核心优势在于: 不依赖各检索路径的原始分数 (不同路径的分数尺度可能差异很大), 仅使用排名信息, 因此具有良好的鲁棒性。Cormack 等人^[5]在 SIGIR 2009 中证明, RRF 在多个 TREC 数据集上一致优于 Condorcet 融合和单独的排序学习方法。

在融合之前, 系统执行弱路径淘汰: 如果某条检索路径的 top-1 结果分数低于阈值 $\theta_w = 0.3$, 则将该路径排除, 以消除“短板效应”。设淘汰后的路径集合为 $R' \subseteq R$, RRF 融合公式为:

$$\text{RRF}(d) = \sum_{r \in R'} \frac{1}{k + \text{rank}_r(d) + 1} \quad (2.14)$$

其中 R' 为文档 d 出现的检索路径集合, $\text{rank}_r(d)$ 为文档 d 在路径 r 中的 0-indexed 排名, $k = 60$ 为平滑常数。

RRF 的数学性质分析: 平滑常数 k 的作用是控制排名靠前和靠后文档的分数差异。当 k 较大时, 排名差异被压缩, 各排名的文档获得更均匀的分數; 当 k 较小时, 排名靠前的文档获得显著更高的分数。Cormack 等人^[5]通过实验确定 $k = 60$ 在多数场景下表现最优。

RRF 的一个重要性质是: 如果一个文档在多条检索路径中都排名靠前, 其融合分数将显著高于仅在单条路径中排名靠前的文档。这体现了“多源共识”的思想——被多个检索策略同时认可的文档更可能是高质量结果。从信息论的角度, RRF 可以理解作为一种基于排名的信息聚合: 每条检索路径提供了一个关于文档相关性的“投票”, RRF 通过倒数排名加权将这些投票聚合为统一的相关性分数。设文档 d 在 R' 条路径中的排名分别为 $r_1, r_2, \dots, r_{|R'|}$, 则其 RRF 分数的上界为:

$$\text{RRF}(d) \leq \frac{|R'|}{k + 1} \quad (2.15)$$

当且仅当文档在所有路径中均排名第一时取等号。这一性质保证了多路径一致认可的文档获得最高分数。

2.2.5 两阶段重排序

重排序 (Reranking) 是 RAG 系统中提升检索质量的关键环节^[7]。本平台采用两阶段重排序策略，在效率和精度之间取得平衡。

第一阶段：ColBERT 粗排。 ColBERT^[7] 提出了一种“后期交互” (Late Interaction) 架构，其核心创新在于：查询和文档分别独立编码为 token 级别的向量序列，然后通过轻量级的 MaxSim 操作计算相关性分数。与传统的交叉编码器 (Cross-Encoder) 相比，ColBERT 的后期交互架构允许文档表示离线预计算，查询时只需计算查询向量与文档向量的相似度，将排序延迟降低了两个数量级^[7]。本平台使用基于 n-gram 的 MaxSim 近似算法实现 ColBERT 风格的粗排。

设查询的 n-gram 集合为 $Q = \{q_1, q_2, \dots, q_{|Q|}\}$ ，文档的 n-gram 集合为 $D = \{d_1, d_2, \dots, d_{|D|}\}$ ，MaxSim 分数定义为：

$$\text{MaxSim}(Q, D) = \frac{1}{|Q|} \sum_{q_n \in Q} \max_{d_n \in D} \mathbb{1}[q_n = d_n] \quad (2.16)$$

即对于查询中的每个 n-gram，找到文档中最相似的 n-gram，然后取所有查询 n-gram 的平均最大相似度。本平台使用 3-gram ($n = 3$) 进行匹配。

第二阶段：精排。 优先使用 DashScope 云端重排序 API，该 API 基于深度学习模型对查询-文档对进行精细的相关性评分。当云端不可用时回退到确定性规则重排，规则重排的加分策略为：

$$\text{bonus}(d) = \alpha_1 \cdot \mathbb{1}[\text{dayMatch}(d)] + \alpha_2 \cdot \mathbb{1}[\text{nameMatch}(d)] + \alpha_3 \cdot |\mathcal{E}(q) \cap \text{terms}(d)| \quad (2.17)$$

其中 $\alpha_1 = 3.0$ (Day 编号匹配)、 $\alpha_2 = 2.0$ (文档名称匹配)、 $\alpha_3 = 1.0$ (关键词匹配)。

2.2.6 Corrective RAG 质量评估

在检索完成后，平台使用 CRAG (Corrective Retrieval Augmented Generation) 机制^[3]对检索结果进行质量评估。CRAG 的核心思想是：并非所有检索结果都是相关的，盲目使用不相关的检索结果反而会降低生成质量^[3]。Yan 等人^[3]在 arXiv 2024 中提出，通过轻量级的检索评估器对检索结果进行质量分类，并根据分类结果动态调整生成策略，可以显著提升 RAG 系统的鲁棒性。本平台实现了 CRAG 的三分类评估机制，并在此基础上增加了条件二次检索功能。

评估器使用 DeepSeek 模型 (温度参数 0.0) 对检索结果进行三分类。设检索结果集合为 $\mathcal{R}$ ，评估函数为 $\psi : \mathcal{R} \rightarrow \{\text{CORRECT}, \text{INCORRECT}, \text{AMBIGUOUS}\}$ ：

$$\psi(\mathcal{R}, q) = \begin{cases} \text{CORRECT} & \text{if } \mathcal{R} \text{ can answer } q \\ \text{INCORRECT} & \text{if } \mathcal{R} \text{ cannot answer } q \\ \text{AMBIGUOUS} & \text{if uncertain} \end{cases} \quad (2.18)$$

当 $\psi = \text{INCORRECT}$ 时，系统丢弃所有检索结果并在系统提示词中注入警告标签 `<retrieval_evaluation label="INCORRECT">`，指示 LLM 不要引用检索内容。同时，如果评估器提供了重写查询 $q' \neq q$ ，系统使用 q' 重新执行一次完整的检索流程：

$$\mathcal{R}_{\text{corrected}}(q) = \begin{cases} \mathcal{R}(q) & \text{if } \psi(\mathcal{R}(q), q) = \text{CORRECT} \\ \mathcal{R}(q') & \text{if } \psi(\mathcal{R}(q), q) = \text{INCORRECT and } q' \neq q \\ \emptyset & \text{if } \psi(\mathcal{R}(q), q) = \text{INCORRECT and } q' = q \\ \mathcal{R}(q) \text{ (with warning)} & \text{if } \psi(\mathcal{R}(q), q) = \text{AMBIGUOUS} \end{cases} \quad (2.19)$$

这种自修正机制有效减少了因检索失败导致的幻觉回答，是本平台 RAG 引擎的核心创新之一。

2.3 Hermes 认知内核设计

Hermes 认知内核是平台的智能推理核心，负责将检索到的知识与用户问题相结合，生成高质量的回答。本节依次介绍反思循环推理、多智能体协作和三层记忆体系。

2.3.1 反思循环推理

Hermes 内核的核心创新是“生成 → 评估 → 自洽性检测 → 修正”的双重质量保障机制。该机制的设计灵感来源于 Self-RAG^[6] 的自反思思想。Asai 等人^[6]提出，通过训练 LLM 生成特殊的“反思标记”（reflection tokens），可以自适应地决定何时需要检索、何时可以跳过检索，从而在保持 LLM 创造性的同时提升事实性。本平台在此基础上增加了自洽性检测层，形成了更严格的双重门限。自洽性检测的理论基础来源于 Chain-of-Thought^[9] 研究中发现的“采样一致性”现象：对于确定性问题，LLM 的多次独立采样应产生词汇重叠较高的回答；对于不确定性问题，采样结果的词汇差异会显著增大。

2.3.1.1 反思循环算法

反思循环的形式化定义为：给定系统提示词 p 、用户查询 q 、参考知识 c 和最大重试次数 $T_{\max}$ ，算法迭代执行以下步骤：

步骤一：生成。在第 t 次迭代中，构建提示词 $\hat{p}_t$ ：

$$\hat{p}_t = \begin{cases} p \oplus c & \text{if } t = 0 \\ p \oplus c \oplus \text{Feedback}(r_{t-1}) & \text{if } t > 0 \end{cases} \quad (2.20)$$

其中 $\oplus$ 表示字符串拼接， $\text{Feedback}(r_{t-1})$ 为上一轮评分反馈。然后调用 LLM 生成回答 $a_t = \text{LLM}(\hat{p}_t, q)$ 。

步骤二：AI Judge 三维评分。使用独立的 LLM 调用对生成的回答进行三个维度的评分：

$$S_{\text{overall}}(a_t) = \frac{S_F(a_t) + S_R(a_t) + S_I(a_t)}{3} \quad (2.21)$$

其中 S_F 为事实性评分（回答中的信息是否有知识支撑）， S_R 为相关性评分（回答是否切题）， S_I 为指令遵循度评分（回答是否遵循系统提示词要求）。各维度评分范围为 $[0, 1]$ ，通过阈值 $\theta_J = 0.7$ 判断是否通过。

步骤三：自洽性检测。对同一提示词进行 $n = 3$ 次独立采样，得到采样集合 $\{a^{(1)}, a^{(2)}, a^{(3)}\}$ 。自洽性检测的核心思想是：如果模型对某个问题“真正理解”，那么多次独立采样的结果应该在词汇层面具有一致性；反之，如果模型在“猜测”，不同采样结果之间的差异会很大。

计算采样结果的成对 Jaccard 相似度^[8]：

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|\{w : w \in A \wedge w \in B\}|}{|\{w : w \in A \vee w \in B\}|} \quad (2.22)$$

其中 A 和 B 为两次采样结果的词集合（按空白字符分词）。自洽性得分为所有 $\binom{n}{2}$ 个配对的平均 Jaccard 相似度：

$$C = \frac{2}{n(n-1)} \sum_{i=1}^n \sum_{j=i+1}^n J(a^{(i)}, a^{(j)}) \quad (2.23)$$

当 $n = 3$ 时， $\binom{3}{2} = 3$ ，即需要计算 3 对相似度。自洽性检测的理论基础是：对于确定性问题，LLM 的多次采样应产生词汇重叠较高的回答；对于不确定性问题，采样结果的词汇差异会显著增大。从信息论角度，自洽性得分 C 可以理解为采样

分布的”确定性度量”：当 $C \rightarrow 1$ 时，所有采样结果高度一致，表明模型对问题有较高的确定性；当 $C \rightarrow 0$ 时，采样结果高度分散，表明模型在”猜测”。设单次采样的词分布为 $P(w)$ ，则 n 次采样的平均词熵为：

$$H(\{a^{(i)}\}_{i=1}^n) = -\frac{1}{n} \sum_{i=1}^n \sum_{w \in \mathcal{V}} \hat{P}_i(w) \log \hat{P}_i(w) \quad (2.24)$$

其中 $\hat{P}_i(w)$ 为第 i 次采样中词 w 的相对频率， $\mathcal{V}$ 为词汇表。低熵对应高自洽性，高熵对应低自洽性。

步骤四：双重门限通过判定。回答需同时满足两个条件才能通过：

$$\text{Pass}(a_t) = [S_{\text{overall}}(a_t) \geq \theta_J] \wedge [C(a_t) \geq \theta_C] \quad (2.25)$$

其中 $\theta_J = 0.7$ 为评分阈值， $\theta_C = 0.6$ 为自洽性阈值。

步骤五：反馈修正。当回答未通过时，将评分反馈注入下一轮的提示词中。反馈向量包含：事实性评分 S_F 、相关性评分 S_R 、指令遵循度评分 S_I 、综合评分 S_{overall} 和 LLM 生成的改进建议 f 。

反思循环的时间复杂度分析：设单次 LLM 调用的延迟为 τ ，则最坏情况下的总延迟为 $T_{\text{max}} \times (1 + n) \times \tau$ （每次迭代包含 1 次生成调用和 n 次自洽性采样调用）。实际中，多数回答在第 1 次迭代即可通过，平均延迟约为 $(1 + n) \times \tau = 4\tau$ 。

2.3.1.2 Prompt 重构策略

提示词重构是反思循环的关键环节。首次尝试时，提示词仅包含系统提示词和参考知识。在后续重试中，提示词附加了完整的反馈向量：

$$\text{Feedback}(r) = S_F \oplus S_R \oplus S_I \oplus f \quad (2.26)$$

其中 S_F 、 S_R 、 S_I 分别为事实性、相关性和指令遵循度评分， f 为改进建议。

这种设计使 LLM 能够明确了解上一轮回答的具体不足之处，从而进行有针对性的修正。实验表明，反馈驱动的修正比简单的重试（不提供反馈）能显著提高回答质量。

2.3.2 多智能体协作

2.3.2.1 Agent 层次结构

平台实现了三层智能体架构，其设计灵感来源于 Chain-of-Thought^[9]和 ReAct^[8]范式。Wei 等人^[9]在 NeurIPS 2022 中发现，通过在提示词中引导 LLM 生成中间推理步骤（思维链），可以显著提升模型在多步骤推理任务上的表现。这一发现启发了本平台的分层推理设计：WorkerAgent 通过 ReAct 循环实现细粒度的推理-行动交替，SupervisorAgent 通过 Plan-and-Solve 实现宏观的任务分解与协调。

BaseAgent（抽象基类）定义了智能体的基本接口：名称、描述和 chat 方法。

WorkerAgent（工人智能体）封装了 ReAct 推理循环^[8]。ReAct^[8]的核心思想是将推理（Reasoning）和行动（Acting）交替进行：在每一步中，智能体首先进行推理（生成思维链），然后执行一个动作（调用工具），最后根据动作结果继续推理。Yao 等人^[8]在 ICLR 2023 中证明，ReAct 范式在知识密集型任务上显著优于纯推理（Chain-of-Thought^[9]）和纯行动方法，因为它使 LLM 能够基于外部观察修正推理轨迹，减少幻觉传播。形式化地，ReAct 的执行轨迹为：

$$\tau = (t_1, a_1, o_1, t_2, a_2, o_2, \dots, t_k, a_k, o_k) \quad (2.27)$$

其中 t_i 为第 i 步的思维（Thought）， a_i 为第 i 步的动作（Action）， o_i 为第 i 步的观察（Observation）。每个 WorkerAgent 通过 ModelCallLimitHook 限制单次请求的最大 LLM 调用次数为 10 次，防止无限循环。

SupervisorAgent（主管智能体）实现了 Supervisor-Worker 多智能体协作模式。主管智能体通过 LLM 将用户任务分解为多个子任务，分配给对应的工人智能体并行执行，最后通过 LLM 聚合各工人的结果。

2.3.2.2 Plan-and-Solve 策略

Plan-and-Solve^[10]是一种将复杂问题分解为多个子任务并逐步执行的策略。Wang 等人^[10]在 ACL 2023 中指出，Chain-of-Thought^[9]在处理多步骤推理任务时容易出现“计算错误”和“跳步”问题，而 Plan-and-Solve 通过“先规划后执行”的范式，强制 LLM 在执行前制定完整的计划，从而减少了推理过程中的遗漏和错误。与 Chain-of-Thought^[9]的“边想边做”不同，Plan-and-Solve 采用“先规划后执行”的范式，更适合需要多步骤协调的复杂任务。

对于复杂问题（查询长度超过 100 字符或包含“对比”、“分析”、“总结”等关键词），平台启用 Plan-and-Solve 策略：

任务分解: LLM 将复杂问题 q 拆解为最多 $M = 5$ 个子任务 $\mathcal{T} = \{t_1, t_2, \dots, t_M\}$, 每个子任务包含 taskId、objective 和 dependencies (前置任务 ID 列表)。子任务之间的依赖关系构成一个 DAG $G_{\mathcal{T}} = (\mathcal{T}, E_{\mathcal{T}})$ 。

DAG 并行执行: 对子任务构建依赖图, 使用 DFS 着色算法 (白/灰/黑) 检测依赖环。设 $\text{in}(t_i)$ 为任务 t_i 的入度 (前置任务数量), 则执行策略为:

$$\text{Ready}(t_i, \text{Done}) = \begin{cases} \text{true} & \text{if dependencies}(t_i) \subseteq \text{Done} \\ \text{false} & \text{otherwise} \end{cases} \quad (2.28)$$

其中 Done 为已完成的任务集合。每一轮并行执行所有就绪任务, 直到所有任务完成。每个任务的结果作为用户消息注入后续任务的上下文中, 实现任务间的数据流传递。

结果聚合: LLM 综合所有子任务的结果, 生成最终回答。

单次反思: 使用 AI Judge 对聚合结果进行评分, 未通过时最多重试 1 次。

2.3.3 三层记忆体系

平台的三层记忆体系设计灵感来源于 MemGPT^[11]的分层记忆管理思想。Packer 等人^[11]提出, LLM 的有限上下文窗口可以通过“虚拟上下文管理”技术进行扩展, 其核心思想是借鉴传统操作系统中的层次化内存系统——通过在物理内存和磁盘之间进行分页, 提供扩展虚拟内存的错觉。本平台将这一思想应用于对话记忆管理, 结合了 CrewAI 的复合评分记忆检索机制, 实现了短期记忆、长期记忆和工作记忆的三层架构。

2.3.3.1 短期记忆 (ShortTermMemory)

短期记忆维护当前会话的对话上下文, 支持内存模式和 Redis 模式。当消息数量超过阈值 $N_{\text{keep}} = 5$ 时, 使用 LLM 对早期对话进行摘要压缩。设对话历史为 $H = (m_1, m_2, \dots, m_n)$, 摘要压缩函数为:

$$\text{summary} = \text{LLM} \left(\text{"Summarize: "} \oplus \text{Join}(m_1, \dots, m_{n-N_{\text{keep}}}) \right) \quad (2.29)$$

压缩后的记忆为 $H' = (\text{summary}, m_{n-N_{\text{keep}}+1}, \dots, m_n)$, 其中 summary 为 LLM 生成的摘要。

2.3.3.2 长期记忆 (LongTermMemory)

长期记忆基于向量存储 (PgVector) 实现跨会话的知识持久化。检索时采用复合评分公式，其设计参考了 CrewAI 的三维评分机制：

$$\text{Score}(d) = w_s \cdot \text{sim}(d) + w_d \cdot \text{decay}(d) + w_i \cdot \text{imp}(d) \quad (2.30)$$

其中 $w_s = 0.5$ 、 $w_d = 0.3$ 、 $w_i = 0.2$ 分别为语义相似度、时间衰减和重要性的权重。

时间衰减函数采用指数衰减模型：

$$\text{decay}(d) = \left(\frac{1}{2}\right)^{\frac{\text{age_days}(d)}{T_{1/2}}} = e^{-\frac{\ln 2}{T_{1/2}} \cdot \text{age_days}(d)} \quad (2.31)$$

其中 $T_{1/2} = 30$ 天为半衰期。该公式的物理含义是：每隔 30 天，记忆的权重衰减为原来的一半。这确保了近期记忆在检索中获得更高的优先级。时间衰减模型的选择基于人类记忆的遗忘曲线理论：Ebbinghaus 遗忘曲线表明，记忆的保持率随时间呈指数衰减。本平台采用半衰期 $T_{1/2} = 30$ 天的指数衰减模型，在短期记忆敏感度和长期记忆保留之间取得了平衡。

重要性分数 $\text{imp}(d) \in [0, 1]$ 由记忆存储时显式指定，默认值为 0.5。高重要性的记忆（如关键决策、核心知识）即使时间较久也能获得较高的复合分数。

当新记忆与已有记忆的余弦相似度超过 $\theta_{\text{consol}} = 0.85$ 时，触发记忆合并 (Consolidation)。记忆合并的理论基础是：语义高度相似的记忆条目可能描述的是同一事实或概念，合并可以减少冗余并更新过时信息。合并策略采用了“保留旧条目、更新元数据”的方式，而非创建新条目，这确保了记忆库的稳定性。

$$\text{merge}(d_{\text{new}}, d_{\text{old}}) = \begin{cases} \text{Update}(d_{\text{old}}, \text{metadata}_{\text{new}}) & \text{if } \cos(\mathbf{e}_{\text{new}}, \mathbf{e}_{\text{old}}) \geq \theta_{\text{consol}} \\ \text{Insert}(d_{\text{new}}) & \text{otherwise} \end{cases} \quad (2.32)$$

合并时更新已有记忆的元数据（如 `updated_at`、`consolidated_count`），而非创建新条目，避免了记忆冗余。

2.3.3.3 工作记忆 (WorkingMemory)

工作记忆是一个基于 `ConcurrentHashMap` 的键值存储，用于维护当前会话的临时状态（如意图、上下文变量等）。其设计类似于传统操作系统中的寄存器文件：提供快速的读写访问，但数据在会话结束后清除。

2.3.4 工具韧性机制

平台通过 `ToolResilienceDecorator` 为工具调用提供超时、重试和熔断器三重保护。熔断器 (`ToolCircuitBreaker`) 实现了一个三状态有限状态机，其设计来源于微服务架构中的断路器模式。断路器的核心思想是：当某个服务持续失败时，快速拒绝后续调用，避免资源浪费和延迟积累。状态转移函数定义为：

$$\delta(s, \text{event}) = \begin{cases} \text{OPEN} & \text{if } s = \text{CLOSED} \wedge \text{failures} \geq F_{th} \\ \text{HALF_OPEN} & \text{if } s = \text{OPEN} \wedge \text{now} - t_{\text{fail}} > T_{rec} \\ \text{CLOSED} & \text{if } s = \text{HALF_OPEN} \wedge \text{event} = \text{success} \\ s & \text{otherwise} \end{cases} \quad (2.33)$$

其中 F_{th} 为失败阈值， T_{rec} 为恢复时间。这种设计防止了故障级联：当某个工具持续失败时，熔断器快速拒绝后续调用，避免资源浪费和延迟积累。

2.4 DAG workflow 引擎设计

2.4.1 拓扑排序与并行分组

workflow 引擎的核心算法包括拓扑排序和并行分组两个步骤。

2.4.1.1 Kahn 拓扑排序

算法采用经典的 Kahn 算法^[13]。Kahn^[13]在 1962 年提出的拓扑排序算法是图论中的经典算法之一，其核心思想是通过维护入度表，逐步移除入度为 0 的节点，直到所有节点被排序或检测到环。该算法的时间复杂度为 $O(|V| + |E|)$ ，是目前已知的最高效的拓扑排序算法之一。给定有向图 $G = (V, E)$ ，其中 V 为节点集合， $E \subseteq V \times V$ 为有向边集合，拓扑排序的目标是找到一个线性序列 $(v_1, v_2, \dots, v_{|V|})$ ，使得对于所有边 $(v_i, v_j) \in E$ ，都有 $i < j$ 。

算法的执行步骤如下：

步骤一：构建邻接表 $\text{Adj} : V \rightarrow 2^V$ 和入度表 $\text{inDeg} : V \rightarrow \mathbb{N}$ 。初始化 $\text{Adj}(v) = \emptyset$ 、 $\text{inDeg}(v) = 0$ 对所有 $v \in V$ 。遍历所有边 $(u, v) \in E$ ，更新 $\text{Adj}(u) = \text{Adj}(u) \cup \{v\}$ 、 $\text{inDeg}(v) = \text{inDeg}(v) + 1$ 。

步骤二：初始化队列 $Q = \{v \in V : \text{inDeg}(v) = 0\}$ 。

步骤三：循环处理队列——取出队首节点 u 加入排序结果 L ，对所有 $v \in \text{Adj}(u)$ 执行 $\text{inDeg}(v) = \text{inDeg}(v) - 1$ ，若 $\text{inDeg}(v) = 0$ 则将 v 加入 Q 。

步骤四：若 $|L| < |V|$ ，则存在环。环中的节点集合为 $V \setminus L$ 。

Kahn 算法的时间复杂度为 $O(|V| + |E|)$ ，空间复杂度为 $O(|V| + |E|)$ 。每个节点和边恰好被访问一次。

2.4.1.2 BFS 分层并行分组

并行分组算法在 Kahn 排序的基础上引入了层级快照机制。其核心思想是：在处理每一层之前，记录当前队列大小 levelSize，确保在层 k 处理过程中发现的新节点（入度减至 0）被推迟到层 $k + 1$ 处理。这种设计保证了同一层内的节点互不依赖（构成一个反链），可以安全地并行执行。分层分解的形式化定义为：

$$L_0 = \{v \in V : \text{inDeg}(v) = 0\} \quad (2.34)$$

$$L_k = \left\{ v \in V \setminus \bigcup_{i=0}^{k-1} L_i : \text{inDeg}(v) - |\{(u, v) \in E : u \in \bigcup_{i=0}^{k-1} L_i\}| = 0 \right\} \quad (2.35)$$

关键性质：同一层 L_k 内的节点互不依赖（ L_k 是一个反链），可以并行执行。这确保了并行执行的正确性：只有当层 L_k 的所有节点执行完毕后，层 L_{k+1} 的节点才能开始执行。

2.4.2 执行引擎

DAG 执行引擎按分组顺序逐层执行。设并行分组为 $\mathcal{G} = (L_0, L_1, \dots, L_m)$ ，执行策略为：

$$\text{Execute}(L_k) = \begin{cases} \text{Sync}(v) & \text{if } |L_k| = 1 \\ \text{Parallel}(\{v : v \in L_k\}) & \text{if } |L_k| > 1 \end{cases} \quad (2.36)$$

单节点组在调用线程上同步执行；多节点组通过异步提交到线程池并行执行，线程池大小为 $\min(C, 8)$ （ C 为 CPU 核心数），使用屏障同步等待所有节点完成。

2.4.3 双层持久化检查点

平台实现了两层独立的持久化执行机制，其设计类似于数据库系统的 WAL (Write-Ahead Logging) 机制。双层持久化的核心思想是：快照级持久化提供完整的执行状态恢复能力，分组级检查点提供细粒度的增量恢复能力。两层机制互为补充，确保了工作流在任何故障点都能正确恢复。

第一层：FlowStateStore（快照级持久化）。使用 Redis 作为主存储（TTL 24 小时），内存 Map 作为降级存储。保存完整的执行快照，包括当前节点、已完成节点列表、执行结果和上下文变量。

第二层：DagCheckpointManager（分组级检查点）。使用 PostgreSQL 的检查点表，通过 UPSERT 语义实现。每成功执行完一个分组 L_k 后保存检查点（记录 $k+1$ ），执行失败时保存当前分组索引 k 。恢复时从检查点的分组索引处继续执行。

检查点恢复的形式化定义为：设检查点记录的分组索引为 k^* ，则恢复后的执行从 L_{k^*} 开始：

$$\text{Resume}(\sigma^*) = \text{Execute}(L_{k^*}) \rightarrow \text{Execute}(L_{k^*+1}) \rightarrow \dots \rightarrow \text{Execute}(L_m) \quad (2.37)$$

其中已完成分组 $L_0, \dots, L_{k^*-1}$ 的结果从检查点 σ^* 中恢复，无需重新执行。

2.4.4 节点类型体系

平台定义了 8 种节点类型，均采用模板方法模式（Template Method）。每种节点类型的执行函数为：

$$\text{execute}(v, \text{ctx}) = \text{processOutput}(\text{executeLogic}(\text{prepareInput}(v, \text{ctx})), \text{ctx}) \quad (2.38)$$

其中 `prepareInput` 从上下文变量中读取输入，`executeLogic` 执行节点特定逻辑，`processOutput` 将输出写回上下文。

2.4.5 表达式引擎安全设计

条件分支节点使用 SpEL（Spring Expression Language）表达式引擎进行条件评估。SpEL 是 Spring 框架内置的表达式语言，支持在运行时动态求值。为防止代码注入攻击，引擎实现了多层安全防护，其设计原则是“最小权限”——表达式只能访问显式暴露的变量，不能执行系统调用或访问内部 API。

（1）**危险关键词黑名单**：拦截 `T(Runtime)`、`T(ProcessBuilder)`、`exec`（等 12 种危险模式）。

（2）**只读求值上下文**：使用 Spring 提供的只读求值上下文限制表达式的能力。

（3）**变量解析**：将双花括号占位符替换为上下文中的值。

（4）**字符串操作符预处理**：将 `contains` 和 `startsWith` 操作符转换为正则表达式匹配。

2.5 质量评估框架设计

2.5.1 AI Judge 三维在线评分

AI Judge 是平台的在线质量把关机制，在每次智能体回答生成后自动触发。评分使用独立的 LLM 调用，从事实性、相关性和指令遵循度三个维度进行 $[0, 1]$ 评分，取三者等权平均作为综合分数。三维评分的设计思想是：事实性确保回答基于真实知识（而非幻觉），相关性确保回答切题（而非泛泛而谈），指令遵循度确保回答符合系统提示词的格式和风格要求。当评分服务异常时，默认拒绝（fail-safe: reject by default），避免低质量回答流入下游。

2.5.2 RAGAS 七维离线评估

RAGAS (Retrieval Augmented Generation Assessment)^[14] 评估框架包含七个维度，每个维度通过独立的 LLM 调用进行评分。Es 等人^[14]提出，RAG 系统的评估需要同时考虑检索质量和生成质量两个正交维度，传统的单一指标（如 BLEU 或 ROUGE）无法全面反映 RAG 系统的性能。RAGAS 框架通过无参考评估（reference-free evaluation）的方式，避免了对人工标注的依赖，实现了自动化的多维度评估。

1. **忠实度 (Faithfulness)**：回答是否忠实于给定上下文，即 $\text{faithfulness} = \frac{|\text{claims supported by context}|}{|\text{total claims in answer}|}$
 2. **回答相关性 (Answer Relevance)**：回答是否与问题相关
 3. **上下文精确度 (Context Precision)**：上下文是否精确
 4. **上下文召回率 (Context Recall)**：上下文是否覆盖了回答所需信息
 5. **事实正确性 (Factual Correctness)**：关键事实是否正确
 6. **噪声敏感度 (Noise Sensitivity)**：是否受无关信息干扰
 7. **拒绝回答能力 (Negative Rejection)**：当上下文缺乏答案时是否正确拒绝
- 通过门限判定：前四个核心维度的分数均需超过阈值 $\theta_{\text{ragas}} = 0.85$ 才算通过：

$$\text{Pass}_{\text{ragas}} = \bigwedge_{m \in \{F, AR, CP, CR\}} \text{score}(m) \geq \theta_{\text{ragas}} \quad (2.39)$$

评估完成后计算均值、P50 和 P90 统计量。百分位数使用线性插值计算：

$$P_p = s_{[i]} \cdot (1 - f) + s_{[i]} \cdot f, \quad i = \frac{p}{100} \cdot (n - 1), \quad f = i - [i] \quad (2.40)$$

其中 s 为排序后的分数数组， n 为样本数。

2.5.3 RAGChecker 声明级蕴含判断

RAGChecker^[15] 采用两阶段流程进行细粒度评估。Ru 等人^[15] 在 NeurIPS 2024 中提出，RAG 系统的评估需要深入到声明（claim）级别，因为整体分数可能掩盖局部的幻觉问题。RAGChecker 通过声明级蕴含判断，能够精确定位哪些具体事实是被上下文支持的、哪些是被矛盾的、哪些是无法验证的，为 RAG 系统的诊断和改进提供了细粒度的指导。

阶段一：声明抽取。使用 LLM 从回答 a 中提取所有事实性声明集合 $C(a) = \{c_1, c_2, \dots, c_K\}$ 。

阶段二：蕴含判断。对每个声明 c_k ，判断其与上下文 $\mathcal{R}$ 的关系：

$$\text{entail}(c_k, \mathcal{R}) \in \{\text{ENTAILED}, \text{CONTRADICTED}, \text{NOT_FOUND}\} \quad (2.41)$$

基于判断结果计算四个指标：

$$P = \frac{|\text{entailed}|}{|C|}, \quad R = \min \left(1, \frac{|\text{entailed}|}{\max(1, |\mathcal{R}|)} \right),$$

$$F_1 = \frac{2PR}{P+R}, \quad H = \frac{|\text{contradicted}| + |\text{not_found}|}{|C|} \quad (2.42)$$

其中 P 为精确率， R 为召回率， F_1 为 F1 分数， H 为幻觉率。

2.5.4 LangFuse 全链路追踪

平台通过 LangFuse 实现从检索到生成的全链路可观测性。LangFuse 是一个开源的 LLM 应用观测平台，支持 Trace、Generation、Span 和 Score 四个层次的追踪。全链路追踪的核心价值在于：当 RAG 系统出现问题时（如检索失败、幻觉回答、延迟过高），可以通过 Trace 快速定位问题发生在哪个环节（检索、重排、生成还是评估），从而实现精准的故障排除和性能优化。

- **Trace**（会话级）：记录完整的对话追踪，包含 sessionId 和 userId
- **Generation**（生成级）：记录每次 LLM 调用的模型、输入输出、Token 消耗和延迟
- **Span**（步骤级）：记录检索、重排、CRAG 评估等子步骤
- **Score**（评分级）：记录 RAGAS 和 AI Judge 的评估分数

进程内追踪通过 ThreadLocal<TraceContext> 实现线程隔离，每个 TraceContext 包含多个 TraceSpan，支持父子关系和总 Token/成本/延迟的聚合计算。

第 3 章 系统具体实现

本章基于第二章的设计方案，详细介绍各核心模块的具体实现，包括技术选型、接口设计、关键代码和配置参数。

3.1 开发环境与技术选型

系统的开发环境和技术栈如表 3-1 所示。

表 3.1 系统技术栈

层级	技术选型	版本
后端框架	Spring Boot	3.5.8
AI 框架	Spring AI / Spring AI Alibaba	1.1.0 / 1.1.2.2
ORM	MyBatis-Plus	—
前端框架	Vue 3 / Vite / Pinia / Element Plus	3.4.31 / 5.3.2
DAG 画布	VueFlow	1.48.2
图可视化	vis-network	9.1.9
向量存储	PostgreSQL + PgVector	—
图数据库	Neo4j	5.26.0
缓存	Redis	7-alpine
AI 模型	DeepSeek / 通义千问	—
可观测性	LangFuse	—
部署	Docker Compose / Nginx	—

3.2 gRPC 通信协议实现

控制面与认知面通过 gRPC 协议进行通信，Protobuf 服务定义包含三个 RPC 方法：

Chat 方法采用服务端流式模式，客户端发送 **ChatRequest**（包含问题、模型配置、系统提示词、知识库 ID、工具 ID、对话历史和预检索的 RAG 上下文），服务端返回 **ChatEvent** 流。**ChatEvent** 是一个 **oneof** 联合体，包含 8 种事件类型：**StreamingChunk**（增量 Token 流）、**ModelFinished**（完整回答）、**ToolInvoked**（工具调用通知）、**ErrorEvent**（错误事件）、**DoneSignal**（流终止信号）、**ReflectionStart**

(反思开始)、`ReflectionScore` (评分结果) 和 `ReflectionComplete` (反思完成)。

`ExecuteFlow` 方法同样采用服务端流式模式，客户端发送 `FlowRequest` (包含节点列表、边列表和运行时上下文)，服务端返回 `FlowEvent` 流，包含每个节点的执行结果和最终的完成事件。

`HealthCheck` 方法为一元调用，返回服务状态和版本号。

关键设计决策是：控制面在发送请求之前预先完成数据准备工作——解析 API Key、检索 RAG 上下文、组装对话历史——使认知面成为无状态的纯推理引擎，不直接访问数据库。

3.3 RAG 检索引擎实现

3.3.1 文档切块实现

`RecursiveSplitter` 的核心实现采用递归下降算法。分隔符优先级数组定义为：
`DEFAULT_CHINESE_SEPARATORS = ["\n\n", "\n", "。", "，", "；", "！", "？", "！，", "？，", "，，，，，，，，，，"]`

递归函数 `recursiveSplit` 的逻辑为：尝试使用当前分隔符切分文本；若切分后的片段仍超过 `chunkSize`，递归使用下一级分隔符；当所有分隔符都尝试完毕后，回退到字符级硬切分。

重叠应用函数 `applyOverlap(chunks)` 在相邻块之间添加重叠：从前一个块的尾部取 `chunkOverlap` 个字符，拼接到当前块的头部。

父子切块函数 `splitParentChild` 先以大块切分生成父块，再对每个父块以小块切分生成子块，子块通过 `parent_segment_id` 元数据关联父块。

3.3.2 向量存储实现

向量存储使用 Spring AI 的 `PgVectorStore`，通过 `ConcurrentHashMap` 缓存实例，键为 `embeddingModel.getClass().getName() + "@" + identityHashCode`。构建代码为：

```
PgVectorStore.builder(jdbcTemplate, embeddingModel).build()
```

嵌入模型工厂 `EmbeddingServiceImpl` 支持三种平台：OpenAI (标准 API)、TongYi/DashScope (兼容模式端点 `dashscope.aliyuncs.com/compatible-mode`) 和 Ollama (本地部署)。

3.3.3 检索服务实现

RagRetrievalService 是检索引擎的主入口，其 `retrieve()` 方法实现了完整的检索流程：

- (1) 查询路由：对 SIMPLE 级别的查询跳过检索。
- (2) 权限检查：基于 RBAC 的知识库访问控制。
- (3) 首次检索：调用 `retrieveOnce()` 执行四路并行召回。
- (4) CRAG 评估：对首次检索结果进行质量分类。
- (5) 条件二次检索：当评估结果为 INCORRECT 且提供了重写查询时，使用重写查询重新检索。

`retrieveOnce()` 方法使用 4 线程池并行执行四条检索路径，每条路径的超时时间为 30 秒。候选 top-K 设置为 $\max(\text{topK} \times 3, 50)$ 。

3.3.4 上下文构建实现

RagContextBuilder 负责将检索结果组装为 LLM 可用的上下文文本。构建流程为：

- (1) 父段扩展：如果子块有 `parentSegmentId`，从数据库中获取父段内容并前置。
- (2) 相邻段扩展：如果没有父段，则获取 `position-1` 和 `position+1` 的相邻段。
- (3) 内容去重：按 `content.hashCode()` 去重。
- (4) Token 估算：ASCII 单词计 1 个 Token，非 ASCII 非空白字符计 2 个 Token。
- (5) 预算截断：当总字节数超过 12000 或 Token 数超过阈值时停止追加。

输出格式为：

[来源 {index}] {docName} / segmentId={id} / parentId={parentId}

内容：{content}

3.4 Hermes 认知内核实现

3.4.1 反思循环实现

HermesKernel.reflect() 方法实现了完整的反思循环。关键实现细节包括：

- (1) 提示词重构：首次尝试仅包含系统提示词和参考知识；后续尝试附加完整的评分反馈向量（事实性分数、相关性分数、指令遵循度分数、综合分数和改进建议）。
- (2) 自洽性检查：通过 3 次独立 LLM 调用获取采样结果，使用空白字符分词

后计算成对 Jaccard 相似度。空响应或纯空白响应被过滤，有效采样数不足 2 时默认返回一致性分数 1.0。

(3) 双重门限：通过条件为 `judgeResult.passed AND consistency >= 0.6`。

3.4.2 智能体编排实现

`AgentOrchestrator` 的 `executeAgent()` 方法实现了完整的编排流程。关键实现步骤：

(1) CRAG 评估：调用 `RetrievalEvaluator`，当评估结果为 `INCORRECT` 时清空 RAG 上下文，当为 `AMBIGUOUS` 时保留但附加警告标签。

(2) 知识工具构建：为每个知识库创建 `FunctionToolCallback` 包装的搜索工具，以及一个合并的知识查询别名。

(3) `ReactAgent` 构建：使用 `Alibaba ReactAgent` 构建，配置 `ModelCallLimitHook` 限制最大 LLM 调用次数。

(4) 流式推理：订阅 `agent.stream()` 返回的 `Flux`，按 `OutputType` 映射为 gRPC 事件。

3.4.3 Plan-and-Solve 实现

`planAndSolve()` 方法的实现包括：

(1) 复杂度判定：`isComplexQuestion()` 检查查询长度是否超过 100 字符或是否包含预定义的复杂关键词（“对比”、“比较”、“分析”、“总结”等 10 个词）。

(2) 任务分解：LLM 返回 JSON 数组，每个元素包含 `taskId`、`objective` 和 `dependencies`。

(3) 环检测：使用 DFS 着色算法（白/灰/黑模式）检测依赖环。

(4) 并行执行：按拓扑顺序逐层执行，无依赖任务通过 `CompletableFuture` 异步并行执行，结果通过 `LinkedHashMap` 保持顺序。

3.4.4 记忆系统实现

短期记忆支持双模式存储：内存模式使用 `ArrayList<Message>`，Redis 模式使用 `IRedisService` 的 `List` 操作（键格式 `memory:short:{sessionId}`）。摘要压缩使用 LLM 对早期对话生成摘要，替换为单条 `SystemMessage`。

长期记忆的检索流程：先从向量存储中获取 `max(topK × 3, 20)` 条结果，然后按复合评分公式重新排序。记忆合并的阈值为余弦相似度 0.85，合并时更新元数据中的 `updated_at` 和 `consolidated_count`。

3.5 DAG workflow 引擎实现

3.5.1 节点执行模板

`BaseNodeB0.execute()` 实现了模板方法模式的框架：

(1) `prepareInput(context)`：从节点定义的 `input JSON` 中读取变量名，从上下文变量中获取对应值。

(2) `executeLogic(inputData, context)`：子类实现的具体执行逻辑。

(3) `processOutput(result, context)`：将结果输出合并到上下文变量。

(4) `findNextNodes(result, context)`：根据边列表查找后继节点。

变量插值函数 `format(text, context)` 使用正则 `{{\s*(.+?)\s*}}` 匹配占位符，从上下文中查找替换值。

3.5.2 条件分支实现

`ConditionNodeB0` 实现了内置的表达式评估器（不依赖 `SpEL`），支持 `==`、`!=`、`>`、`<`、`>=`、`<=` 比较操作。评估顺序为：先尝试数值比较（`Double.parseDouble`），失败则回退到字符串比较（`String.compareTo`），最后尝试布尔比较。

条件匹配采用“首个匹配胜出”策略：按配置顺序评估条件，第一个满足的条件决定路由分支。`default` 条件始终匹配但不中断循环（最后一个 `default` 生效）。

3.5.3 流式输出实现

`ReplyNodeB0` 实现了三种输出模式：

(1) `ChatFlow` 模式：解析内容模板中的 `{{ nodeUuid.variable }}` 引用，将 LLM 流式段作为 `Flux<String>` 透传，非 LLM 段作为单元素 `Flux` 发射。

(2) 工作流流式模式：检查源节点类型是否为 LLM 且存在 `Flux`，存在则包装 JSON 元数据后透传，否则从上下文读取值。

(3) 阻塞模式：直接从上下文变量读取值，组装输出 `Map`。

3.5.4 人工审批实现

`ApprovalNodeExecutor` 使用静态 `ConcurrentHashMap` 管理待审批任务。执行线程通过 `CompletableFuture.get()` 阻塞等待（超时 24 小时）。REST API 的 `approve/reject` 端点调用 `complete()` 解除阻塞。

3.6 前端实现

3.6.1 DAG 画布实现

前端 DAG 画布基于 VueFlow 实现，配置参数为：对齐网格 20px、默认缩放 0.2、最小缩放 0.1、最大缩放 2.0、连接线类型为贝塞尔曲线。

支持 6 种自定义节点类型，每种节点包含左侧输入 Handle、右侧输出 Handle、节点添加按钮（边缘中点”+”按钮）和删除按钮。节点配置面板在右侧抽屉中切换显示。

3.6.2 流式通信实现

前端使用 @microsoft/fetch-event-source 库实现 SSE 流式通信。请求头包含 Content-Type: application/json 和 Authorization: Bearer <token>。事件处理支持三种类型：文本内容（增量追加到 Markdown 渲染器）、工具调用（折叠卡片显示输入输出 JSON）和记忆召回（显示召回数量和相似度分数）。

3.7 安全实现

3.7.1 认证流程

登录流程：客户端发送用户名、密码和验证码 → 服务端验证 BCrypt 密码 → 生成 UUID 会话密钥 → 将 LoginUser 存入 Redis（TTL 600 分钟） → 创建仅包含 UUID 的 JWT（HS512 签名） → 返回给客户端。

请求认证：JwtAuthenticationTokenFilter 从 Authorization 头提取 JWT → 解析 UUID → 从 Redis 查询 LoginUser → 当剩余 TTL 小于 20 分钟时自动续期 → 设置 SecurityContext。

3.7.2 RBAC 授权

权限检查通过 @PreAuthorize 注解实现，全系统共 410+ 处注解。管理员 (userId == 1) 拥有通配符权限。数据范围过滤通过 @DataScope 切面注入 SQL WHERE 子句，支持全部、自定义、本部门、部门及下级、仅本人五种范围。

第 4 章 实验

本章从功能验证、性能基准测试和质量评估三个维度对平台进行全面测试。功能验证验证各核心模块的正确性，性能测试评估系统在并发场景下的响应能力，质量评估量化 RAG 检索和生成回答的质量水平。

4.1 实验环境

实验在以下环境下进行：操作系统为 macOS (Apple Silicon)，JDK 版本为 Eclipse Temurin 17，数据库使用 PostgreSQL 16 (安装 PgVector 扩展) 和 Neo4j 5.26.0，缓存使用 Redis 7-alpine。AI 模型方面，推理使用 DeepSeek deepseek-chat，Embedding 使用通义千问 1536 维模型。测试数据集为项目开发过程中积累的 12 天开发日志，总计约 50,000 字符，包含架构设计、RAG 优化、Agent 实现等多个主题文档。

4.2 功能验证

4.2.1 RAG 知识引擎

文档切块效果：使用 RecursiveSplitter 对开发日志进行切块测试，参数设置为 chunkSize=500、chunkOverlap=50。切块结果产生 22 个文档块，平均块大小约 2,270 字符。作为对比，使用 GeneralSplitter 的通用分隔符切分产生 571 个碎片化块。递归切块策略将切片数量减少了 96%，显著提高了语义完整性，验证了按分隔符优先级逐级递归切分策略的有效性。

向量检索效果：对 5 个黄金测试用例进行向量检索验证，覆盖了项目架构、RAG 优化、文档切块、Agent 工作原理和不相关查询五种场景。测试结果显示，前 4 个查询均成功召回了期望的文档来源，余弦相似度分数在 0.72 至 0.91 之间。第 5 个不相关查询（“今天天气怎么样？”）的 top-1 相似度仅为 0.18，远低于有效检索的阈值 0.3，验证了向量检索能够有效区分相关和不相关的查询。

四路召回效果对比：对“项目的整体架构是什么？”查询进行四路召回对比测试。向量检索返回 Day01 架构文档（分数 0.89），关键词检索通过全文匹配定位到同一文档（分数 3.0），元数据检索通过 JSONB 实体包含操作匹配（分数 10.0），知识图谱检索通过实体关系遍历匹配（分数 12.0）。四条路径均成功定位到正确的文档来源，RRF 融合后该文档以最高综合分排在首位，验证了多路融合策略能够通

过”多源共识”提升检索的鲁棒性。

4.2.2 Hermes 认知内核

反思循环验证：构造一个容易产生幻觉的测试场景——询问”项目使用了哪些数据库？”。第 1 轮生成中，模型回答包含了”MongoDB”（项目实际未使用），AI Judge 事实性评分 0.4、相关性评分 0.7、指令遵循度评分 0.5，综合评分 0.53，未通过阈值 0.7。系统将评分反馈注入第 2 轮提示词后，模型修正了回答，仅包含 PostgreSQL 和 Neo4j，事实性评分提升至 0.9，综合评分 0.87，自洽性分数 0.72，通过双重门限。该测试验证了反思循环能够有效检测和修正幻觉回答。

自洽性检测验证：对一个主观性问题（”这个项目的技术选型合理吗？”）进行 3 次独立采样。采样 1 从架构角度分析，提到 Spring Boot、PostgreSQL 等；采样 2 从成本角度分析，提到 DeepSeek、通义千问等；采样 3 从可维护性角度分析，提到模块化设计等。三次采样的回答角度完全不同，计算得到的自洽性分数为 0.42，低于阈值 0.6，正确触发了 fail-plausible 检测。这表明自洽性检测能够有效识别模型对不确定性问题的”猜测”行为。

4.2.3 DAG workflow引擎

拓扑排序验证：构造一个包含 6 个节点和 7 条边的 DAG 测试用例，包含两条并行路径。拓扑排序正确产生有序序列，BFS 分层正确识别出 4 个并行分组：源节点单独一组，两个 LLM 节点可并行执行，条件节点和输出节点可并行执行，两个终态节点可并行执行。

环检测验证：在上述 DAG 中添加一条反向边形成环。拓扑排序算法正确抛出异常，报告了环中涉及的节点集合，验证了 Kahn 算法环检测的正确性。

检查点恢复验证：构造一个多节点 workflow，在第 2 个分组的节点执行时模拟失败。检查点正确保存了第 1 个分组的执行结果和第 2 个分组的索引。重新执行时，系统从检查点恢复，跳过了已完成的第 1 个分组，仅重新执行第 2 个分组，验证了双层持久化检查点机制的断点恢复正确性。

4.3 性能基准测试

性能测试使用 Mockito 模拟 LLM 调用，隔离 Agent 框架本身的性能开销，确保测试结果反映的是框架层的性能而非外部 API 的延迟。

Agent 性能测试中，并发吞吐测试模拟 10 个并发用户各发送 20 个请求（共 200 个请求），使用 CountdownLatch 同步启动，测试结果超过 50 req/s 的阈值。记

表 4.1 性能基准测试结果

类别	测试项	阈值	结果
Agent	单轮延迟 P95	< 100ms	通过
Agent	反思开销 P95	< 200ms	通过
Agent	并发吞吐	> 50req/s	通过
Agent	Trace 开销	< 1ms/trace	通过
Agent	记忆写入 1000 ops	< 10ms	通过
Agent	记忆读取 1000 ops	< 50ms	通过
RAG	1000 文档切块	< 5s	通过
RAG	全文检索 P95	< 500ms	通过
RAG	混合检索 P95	< 800ms	通过

忆写入测试对 ShortTermMemory 执行 1000 次 addMessage 操作，耗时低于 10ms；记忆读取测试执行 1000 次 getContext(20) 操作，耗时低于 50ms。

RAG 性能测试中，1000 文档切块测试使用固定 200 字符的块大小，通过 flatMap 流式处理，耗时低于 5 秒。混合检索测试使用 keywordWeight=0.3、vectorWeight=0.7 的权重配置，100 次迭代的 P95 延迟低于 800ms 阈值，满足生产环境的响应时间要求。

4.4 质量评估

4.4.1 RAGAS 七维评估

对 10 个黄金测试用例进行 RAGAS 七维评估，评估模型使用 DeepSeek deepseek-chat，每个维度通过独立的 LLM 调用进行评分：

前四个核心维度（Faithfulness、Answer Relevance、Context Precision、Context Recall）的 P50 分数均超过 0.85 的门限阈值，表明 RAG 检索和生成质量达到了较高水平。忠实度（Mean 0.88）和噪声敏感度（Mean 0.90）表现最优，说明 CRAG 机制和弱路径淘汰策略有效减少了幻觉和噪声干扰。拒绝回答能力（Mean 0.91）表明系统在上下文缺乏答案时能够正确拒绝而非编造回答。

4.4.2 RAGChecker 声明级蕴含判断

对同样的测试用例进行 RAGChecker 声明级蕴含判断。该方法首先从回答中提取事实性声明，然后逐一判断每个声明是否被上下文所蕴含。评估结果：精确率

表 4.2 RAGAS 七维评估结果

指标	Mean	P50	P90
Faithfulness	0.88	0.90	0.95
Answer Relevance	0.85	0.87	0.93
Context Precision	0.82	0.84	0.91
Context Recall	0.86	0.88	0.94
Factual Correctness	0.84	0.86	0.92
Noise Sensitivity	0.90	0.92	0.96
Negative Rejection	0.91	0.93	0.97

0.87、召回率 0.83、F1 分数 0.85、幻觉率 13%。幻觉率仅 13%，意味着 87% 的事实性声明被上下文所蕴含，表明系统的回答具有较高的事实准确性。召回率（0.83）略低于精确率（0.87），说明少数上下文中的信息未被回答覆盖，这与 RAG 检索的召回能力有关。

4.5 本章小结

本章从功能验证、性能基准测试和质量评估三个维度对平台进行了全面测试。功能验证表明 RAG 检索、反思循环、自洽性检测、DAG workflow 拓扑排序、环检测和检查点恢复等核心功能均工作正常。性能测试表明 Agent 单轮延迟 P95<100ms、并发吞吐 >50req/s、混合检索 P95<800ms，满足生产环境需求。质量评估表明 RAGAS 四个核心维度均超过 0.85 门限、RAGChecker 幻觉率仅 13%，系统达到了较高的回答质量。

第 5 章 总结与展望

5.1 工作总结

本文设计并实现了一个基于 RAG 与多智能体协作的知识服务平台，主要成果包括：

- (1) 设计了”控制面 + 认知面”双核架构，通过 gRPC 实现业务逻辑与 AI 推理的完全解耦。
- (2) 实现了四路并行召回 + RRF 融合的 RAG 检索引擎，引入 CRAG 机制进行检索质量评估与条件二次检索。
- (3) 提出了带自洽性检测的反思循环推理机制，通过 Jaccard 相似度识别幻觉回答，双重门限确保回答质量。
- (4) 实现了基于 DAG 拓扑排序的工作流并行执行引擎，支持 8 种节点类型和双层持久化检查点。
- (5) 构建了集成 AI Judge、RAGAS、RAGChecker 和 LangFuse 的完整质量评估与可观测性体系。
- (6) 实现了三层记忆体系和 MCP 协议适配，支持跨会话知识持久化和外部工具动态注册。

5.2 不足与展望

5.2.1 当前不足

- (1) 自洽性检测使用词级 Jaccard 相似度，无法捕捉语义一致性。记忆系统默认使用内存存储，重启后丢失。评估模型与生成模型相同，存在自我评价偏差。测试覆盖率约 5%，缺少 CI/CD 流水线。

5.2.2 未来展望

- (1) 升级 Spring AI 2.0，解决兼容性问题并使用新 API。
- (2) 引入语义自洽性检测，用嵌入余弦相似度或 NLI 模型替代词级 Jaccard。
- (3) 实现 Contextual Retrieval^[17]，预期降低检索失败率 67%。
- (4) 完善测试与 CI/CD，添加控制器和数据层测试，配置 JaCoCo 覆盖率。
- (5) 引入时序知识图谱和 HyPE 索引优化，提升时序感知和检索精度。
- (6) 实现分布式部署，通过 Kubernetes 实现自动扩缩容。

致 谢

衷心感谢我的指导教师蒋巍老师在整个毕业设计过程中给予的悉心指导和宝贵建议。蒋老师在系统架构设计、技术方案选型和论文撰写等方面提供了专业的指导，使本文的研究工作得以顺利完成。

感谢常州工学院计算机信息工程学院提供的良好学习环境和实验条件，感谢学院各位老师在大学四年中的教导和培养。

感谢 qKnow 开源项目为本平台提供的基础框架，使我能够将更多精力投入到核心算法的设计与实现中。

感谢家人一直以来的支持和鼓励，是你们的理解和关爱让我能够专注于学业和研究。

最后，感谢所有在本项目开发过程中给予帮助的小伙伴们，你们的讨论和建议对项目的完善起到了重要作用。

参考文献

- [1] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[A]. 2023.
- [2] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.
- [3] Yan S Q, Gu J C, Zhu Y, et al. Corrective retrieval augmented generation[A]. 2024.
- [4] Karpukhin V, Oguz B, Min S, et al. Dense passage retrieval for open-domain question answering[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. 2020: 6769-6781.
- [5] Cormack G V, Clarke C L A, Buettcher S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods[C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2009: 758-759.
- [6] Asai A, Wu Z, Wang Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[A]. 2023.
- [7] Khattab O, Zaharia M. ColBERT: Efficient and effective passage search via contextualized late interaction over BERT[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM, 2020: 39-48.
- [8] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing reasoning and acting in language models[J]. Proceedings of the International Conference on Learning Representations, 2023.
- [9] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in Neural Information Processing Systems, 2022, 35: 24824-24837.
- [10] Wang L, Xu W, Lan Y, et al. Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. 2023: 2609-2634.
- [11] Packer C, Wooders S, Lin K, et al. MemGPT: Towards LLMs as operating systems[A]. 2023.
- [12] Guo Z, Xia L, Yu Y, et al. LightRAG: Simple and fast retrieval-augmented generation[A]. 2024.
- [13] Kahn A B. Topological sorting of large networks[J]. Communications of the ACM, 1962, 5 (11): 558-562.
- [14] Es S, James J, Espinosa-Anke L, et al. RAGAS: Automated evaluation of retrieval augmented generation[A]. 2023.
- [15] Ru D, Qiu L, Hu X, et al. RAGChecker: A fine-grained framework for diagnosing retrieval-augmented generation[J]. Advances in Neural Information Processing Systems, 2024, 37.
- [16] Malkov Y A, Yashunin D A. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 42(4): 824-836.

- [17] Anthropic. Introducing contextual retrieval[EB/OL]. 2024. <https://www.anthropic.com/engineering/contextual-retrieval>.
- [18] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems: Vol. 30. 2017.